

機器學習 HW2


Part2

	\mathbf{W}^T	b	CR
第一次分類	[-2.09, -10.46]	28.12	94.00%
第二次分類	[-3.73, -7.85]	31.05	94.00%


Average CR = 94.00%

```
權重向量 w: [[ -2.09 -10.46]]  
偏置項 b: [[28.12]]  
分類率: 94.00%  
權重向量 w: [[-3.73 -7.85]]  
偏置項 b: [[31.05]]  
分類率: 94.00%  
平均分類率: 94.00%
```


Part3



圖(一)：使用特徵 1~4 的 ROC 曲線



圖(二)：使用特徵 1~2 的 ROC 曲線



圖(三): 使用特徵 3~4 的 ROC 曲線

	CR	AUC
使用特徵 1~4	97.00%	0.99
使用特徵 1~2	72.00%	0.85
使用特徵 3~4	94.00%	0.99

ROC 曲線代表模型在不同分類閾值下的分類表現，展示了 TPR 與 FPR 之間的權衡。我們可以通過分析這條曲線來選擇最合適的閾值，並根據應用需求中的正負類分類成本比率（Cp/Cn），來優化模型的性能。從圖中也能看出橘線下包含的面積越大 AUC 越大。

從圖(一)和圖(三)可以看到，FPR 接近 0，TPR 接近 1，這說明模型幾乎沒有將負例錯誤分類為正例的情況，同時能夠識別出大部分正例。然而，圖(二)的 ROC 曲線顯示出明顯的階梯形狀，反映了模型的分類效果有波動。這表示在不同的閾值下，FPR 和 TPR 之間存在較大的折衷，導致模型在一些閾值下會產生一定的誤判和準確率的變化。這些差異也反映在它們的 AUC 值上，圖(一)和圖(三)的 AUC 值較高，說明分類效果接近完美，而圖(二)的 AUC 為 0.85，相對較低，說明該模型的分類性能雖然不錯，但仍然存在改進的空間，可能在某些情況下更容易將負例錯誤分類為正例。

他們的 CR 分別為 97%、72%和 94%，這與他們的 AUC 高度相關。因此，AUC 是衡量模型整體分類能力的重要指標，而 CR 則反映了模型在特定閾值下的表現。將兩者結合起來，可以更全面地評估模型的分類性能。

Part4

CR1 = 96.00%

CR2 = 96.00%

Average CR = 96.00%

```
權重向量 w: [[-19.67 -15.01]]  
偏置項 b: [[68.72]]  
權重向量 w: [[-12.65 -34.96]]  
偏置項 b: [[84.97]]  
權重向量 w: [[ -2.09 -10.46]]  
偏置項 b: [[28.12]]  
CR1: 96.00%  
權重向量 w: [[-14.67 -17.11]]  
偏置項 b: [[54.88]]  
權重向量 w: [[-34.15 -23.52]]  
偏置項 b: [[144.8]]  
權重向量 w: [[-3.73 -7.85]]  
偏置項 b: [[31.05]]  
CR2: 96.00%  
Average CR: 96.00%
```

Part5

本週作業使用 LDA 分類器的結果顯示，使用特徵 3 和 4 進行分類能夠達到較高的分類準確率（CR），這與上週的散佈圖（scatter plot）結果高度一致。下圖為特徵 3 和 4 的散佈圖，顯示了 Class 2 和 Class 3 之間的明顯區分。在 Part 2 中，針對 Class 2 和 Class 3 的分類，LDA 分類器達到了 94% 的準確率。當在 Part 4 中加入 Class 1 後，分類準確率進一步提升，顯示出 LDA 分類器在多類別情境下依然具備優異的分類能力

從 ROC 曲線與 AUC 的角度來看，使用特徵 3 和 4 時的 AUC 值較高，顯示這兩個特徵在不同閾值下均具備良好的區分能力，這與分類結果相符。而且即使 LDA 只能進行二元分類，我們仍然可以通過 OAO 方法（One against One）來應對多類別問題。

